

Липецкий государственный технический университет

Кафедра прикладной математики

КОМПЬЮТЕРНЫЕ ТЕХНОЛОГИИ МАТЕМАТИЧЕСКИХ ИССЛЕДОВАНИЙ

Лекция 9

Анализ временных рядов

Составитель - Сысоев А.С., к.т.н., доцент

Липецк - 2020

Outline

- 9.1. Задачи анализа временных рядов
- 9.2. Создание объектов типа временной ряд в среде R
- 9.3. Процедура скользящего среднего в среде R
- 9.4. Сезонная декомпозиция в среде R
- 9.5. Экспоненциальные модели прогнозирования временных рядов в среде R
- 9.6. Модели ARIMA в среде R

9.1. Задачи анализа временных рядов



Данные бывают:

- Перекрестными – предполагается наблюдение за многими однотипными объектами с целью получения информации о процессе / объекте / системе.
- Долгосрочными (лонгитюдными) – изучается одна и та же группа объектов в течении долгого времени, за которое эти объекты успевают существенным образом поменять какие-либо свои значимые признаки.

Возможно выстроить результаты наблюдения таким образом, чтобы они образовывали временной ряд $Y_1, Y_2, Y_3, \dots, Y_t, \dots, Y_T$.

Анализ временных рядов строится для решения двух основных задач:

1. Исследовать то, что происходит (задача описания).
2. Сказать, что будет дальше (задача прогноза).



9.2. Создание объектов типа временной ряд в среде R

Необходимые составляющие объекта типа временной ряд:

- Непосредственно наблюдения,
- Время начала и конца рассматриваемого временного периода,
- Информация о периодичности (месячные данные, квартальные или годовые).

```
myseries <- ts(data, start=, end=, frequency=)
```

```
> sales <- c(18, 33, 41, 7, 34, 35, 24, 25, 24, 21, 25, 20,
             22, 31, 40, 29, 25, 21, 22, 54, 31, 25, 26, 35)
> tsales <- ts(sales, start=c(2003, 1), frequency=12)
> tsales
      Jan Feb Mar Apr May Jun Jul Aug Sep Oct Nov Dec
2003  18  33  41   7  34  35  24  25  24  21  25  20
2004  22  31  40  29  25  21  22  54  31  25  26  35
> plot(tsales)
> start(tsales)
[1] 2003    1
> end(tsales)
[1] 2004   12
> frequency(tsales)
[1] 12
> tsales.subset <- window(tsales, start=c(2003, 5), end=c(2004, 6))
> tsales.subset
      Jan Feb Mar Apr May Jun Jul Aug Sep Oct Nov Dec
2003           34  35  24  25  24  21  25  20
2004  22  31  40  29  25  21
```

←
1 Creates a
time-series
object

←
2 Gets information
about the object

Subsets the object **3**

9.3. Процедура скользящего среднего в среде R

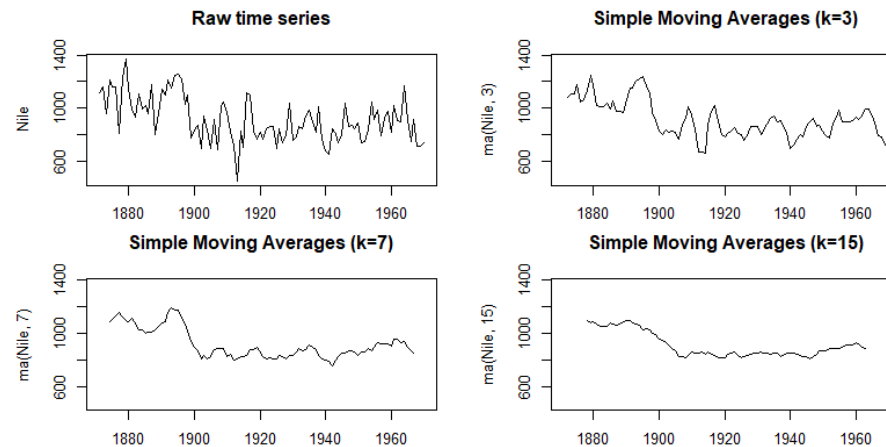
Обычно временные ряды имеют значимую нерегулярную компоненту или ошибку.

Подход – использовать процедуру скользящего среднего.

Центрированное скользящее среднее (теряется $(k - 1) / 2$ значений)

$$S_t = (Y_{t-q} + \dots + Y_t + \dots + Y_{t+q}) / (2q + 1)$$

```
library(forecast)
opar <- par(no.readonly=TRUE)
par(mfrow=c(2,2))
ylim <- c(min(Nile), max(Nile))
plot(Nile, main="Raw time series")
plot(ma(Nile, 3), main="Simple Moving Averages (k=3)", ylim=ylim)
plot(ma(Nile, 7), main="Simple Moving Averages (k=7)", ylim=ylim)
plot(ma(Nile, 15), main="Simple Moving Averages (k=15)", ylim=ylim)
par(opar)
```



9.4. Сезонная декомпозиция в среде R


Временной ряд, у которого присутствует сезонная составляющая (месячная или квартальная периодичность), можно разложить на тренд, сезонную компоненту и ошибку.

Декомпозиция может быть представлена аддитивной или мультипликативной моделями.


$$Y_t = \text{Trend}_t + \text{Seasonal}_t + \text{Irregular}_t$$

$$Y_t = \text{Trend}_t * \text{Seasonal}_t * \text{Irregular}_t$$


(a) Stationary




(b) Additive Trend and Irregular Components




(c) Additive Seasonal and Irregular Components



(d) Additive Trend, Seasonal, and Irregular Components



(e) Multiplicative Trend, Seasonal, and Irregular Components





9.4. Сезонная декомпозиция в среде R

Популярный метод декомпозиции в R – loess (Local regrESSion).

```
stl(ts, s.window=, t.window=)
```

Такой подход применяется только к аддитивным моделям. В случае мультипликативных моделей используется линеаризация:

$$\begin{aligned}\log(Y_t) &= \log(\text{Trend}_t * \text{Seasonal}_t * \text{Irregular}_t) = \\ &= \log(\text{Trend}_t) + \log(\text{Seasonal}_t) + \log(\text{Irregular}_t)\end{aligned}$$



9.4. Сезонная декомпозиция в среде R

```
> plot(AirPassengers)
> lAirPassengers <- log(AirPassengers)
> plot(lAirPassengers, ylab="log(AirPassengers)")
```

←
1 Plots the time series

```
> fit <- stl(lAirPassengers, s.window="period")
> plot(fit)
```

←
2 Decomposes the time series

```
> fit$time.series
```


←
3 Components for each observation

| | seasonal | trend | remainder |
|------------------------|----------|-------|------------|
| Jan 1949 | -0.09164 | 4.829 | -0.0192494 |
| Feb 1949 | -0.11403 | 4.830 | 0.0543448 |
| Mar 1949 | 0.01587 | 4.831 | 0.0355884 |
| Apr 1949 | -0.01403 | 4.833 | 0.0404633 |
| May 1949 | -0.01502 | 4.835 | -0.0245905 |
| Jun 1949 | 0.10979 | 4.838 | -0.0426814 |
| Jul 1949 | 0.21640 | 4.841 | -0.0601152 |
| Aug 1949 | 0.20961 | 4.843 | -0.0558625 |
| Sep 1949 | 0.06747 | 4.846 | -0.0008274 |
| Oct 1949 | -0.07025 | 4.851 | -0.0015113 |
| Nov 1949 | -0.21353 | 4.856 | 0.0021631 |
| Dec 1949 | -0.10064 | 4.865 | 0.0067347 |
| ... output omitted ... | | | |



```
> exp(fit$time.series)
```

| | seasonal | trend | remainder |
|------------------------|----------|-------|-----------|
| Jan 1949 | 0.9124 | 125.1 | 0.9809 |
| Feb 1949 | 0.8922 | 125.3 | 1.0558 |
| Mar 1949 | 1.0160 | 125.4 | 1.0362 |
| Apr 1949 | 0.9861 | 125.6 | 1.0413 |
| May 1949 | 0.9851 | 125.9 | 0.9757 |
| Jun 1949 | 1.1160 | 126.2 | 0.9582 |
| Jul 1949 | 1.2416 | 126.6 | 0.9417 |
| Aug 1949 | 1.2332 | 126.9 | 0.9457 |
| Sep 1949 | 1.0698 | 127.2 | 0.9992 |
| Oct 1949 | 0.9322 | 127.9 | 0.9985 |
| Nov 1949 | 0.8077 | 128.5 | 1.0022 |
| Dec 1949 | 0.9043 | 129.6 | 1.0068 |
| ... output omitted ... | | | |

9.4. Сезонная декомпозиция в среде R



```
par(mfrow=c(2,1))
library(forecast)
monthplot(AirPassengers, xlab="", ylab="")
seasonplot(AirPassengers, year.labels="TRUE", main="")
```



9.5. Экспоненциальные модели прогнозирования временных рядов в среде R

Экспоненциальные модели, используемые для прогнозирования временных рядов:

- single exponential model (используется для рядов с постоянным уровнем и ошибкой, но без тренда и сезонной составляющей);
- double exponential model (Holt exponential smoothing) для рядов с постоянным уровнем и трендом.
- triple exponential model (Holt-Winters exponential smoothing) для рядов с постоянным уровнем, трендом и сезонной составляющей.

Функция `ets()` из пакета `forecast`:

`ets(ts, model="ZZZ")`

Доступные опции:

- A – аддитивные модели,
- M – мультипликативные модели,
- N – не указано,
- Z – автоматический выбор.

| Type | Parameters fit | Functions |
|--------|------------------------|--|
| simple | level | <code>ets(ts, model="ANN")</code> <code>ses(ts)</code> |
| double | level, slope | <code>ets(ts, model="AAN")</code> <code>holt(ts)</code> |
| triple | level, slope, seasonal | <code>ets(ts, model="AAA")</code> <code>hw(ts)</code> |

9.5. Экспоненциальные модели прогнозирования временных рядов в среде R


Простое экспоненциальное скользящее:

$$Y_t = \text{level} + \text{irregular}_t$$

Прогнозное значение для уровня Y_{t+1}

$$Y_{t+1} = c_0 Y_t + c_1 Y_{t-1} + c_2 Y_{t-2} + c_2 Y_{t-2} + \dots$$

$$c_i = \alpha(1-\alpha)^i, i = 0, 1, 2, \dots \text{ and } 0 \leq \alpha \leq 1.$$



```
> library(forecast)
> fit <- ets(nhtemp, model="ANN") 1 Fits the model
> fit
ETS(A,N,N)
Call:
ets(y = nhtemp, model = "ANN")
Smoothing parameters:
  alpha = 0.182
Initial states:
  l = 50.2759
  sigma = 1.126
AIC AICc BIC
263.9 264.1 268.1
> forecast(fit, 1) 2 I-step ahead forecast
      Point Forecast Lo 80 Hi 80 Lo 95 Hi 95
1972      51.87 50.43 53.31 49.66 54.08
> plot(forecast(fit, 1), xlab="Year",
       ylab=expression(paste("Temperature (", degree*"F", ")")),
       main="New Haven Annual Mean Temperature")
> accuracy(fit) 3 Prints accuracy measures
      ME  RMSE  MAE  MPE  MAPE  MASE
Training set 0.146 1.126 0.8951 0.2419 1.749 0.9228
```

9.5. Экспоненциальные модели прогнозирования временных рядов в среде R

accuracy()

| Measure | Abbreviation | Definition |
|--------------------------------|--------------|---|
| Mean error | ME | $\text{mean}(e_t)$ |
| Root mean squared error | RMSE | $\sqrt{\text{mean}(e_t^2)}$ |
| Mean absolute error | MAE | $\text{mean}(e_t)$ |
| Mean percentage error | MPE | $\text{mean}(100 * e_t / Y_t)$ |
| Mean absolute percentage error | MAPE | $\text{mean}(100 * e_t / Y_t)$ |
| Mean absolute scaled error | MASE | $\text{mean}(q_t)$ where $q_t = e_t / (1/(T-1) * \sum(y_t - y_{t-1}))$, T is the number of observations, and the sum goes from t=2 to t=T |


9.5. Экспоненциальные модели прогнозирования временных рядов в среде R

Экспоненциальное скользящее Хольта:

$$Y_t = \text{level} + \text{slope} * t + \text{irregular}_t$$

Экспоненциальное скользящее Хольта-Винтерса:

$$Y_t = \text{level} + \text{slope} * t + s_t + \text{irregular}_t$$



```
> library(forecast)
> fit <- ets(log(AirPassengers), model="AAA")
> fit
ETS (A,A,A)
Call:
ets(y = log(AirPassengers), model = "AAA")
Smoothing parameters: 1 Smoothing parameters
  alpha = 0.8528
  beta  = 4e-04
  gamma = 0.0121
Initial states:
  l = 4.8362
  b = 0.0097
  s = -0.1137 -0.2251 -0.0756 0.0623 0.2079 0.2222
      0.1235 -0.009 0 0.0203 -0.1203 -0.0925
sigma: 0.0367
AIC   AICc   BIC
-204.1 -199.8 -156.5
> accuracy(fit)
           ME      RMSE      MAE      MPE      MAPE      MASE
Training set -0.0003695 0.03672 0.02835 -0.007882 0.5206 0.07532
```

```
> pred <- forecast(fit, 5) 2 Future forecasts
> pred
      Point Forecast Lo 80 Hi 80 Lo 95 Hi 95
Jan 1961      6.101 6.054 6.148 6.029 6.173
Feb 1961      6.084 6.022 6.146 5.989 6.179
Mar 1961      6.233 6.159 6.307 6.120 6.346
Apr 1961      6.222 6.138 6.306 6.093 6.350
May 1961      6.225 6.131 6.318 6.082 6.367

> plot(pred, main="Forecast for Air Travel",
       ylab="Log(AirPassengers)", xlab="Time")
> pred$mean <- exp(pred$mean)
> pred$lower <- exp(pred$lower)
> pred$upper <- exp(pred$upper) 3 Makes forecasts in
                                the original scale
> p <- cbind(pred$mean, pred$lower, pred$upper)
> dimnames(p)[[2]] <- c("mean", "Lo 80", "Lo 95", "Hi 80", "Hi 95")
> p
      mean Lo 80 Lo 95 Hi 80 Hi 95
Jan 1961 446.3 425.8 415.3 467.8 479.6
Feb 1961 438.8 412.5 399.2 466.8 482.3
Mar 1961 509.2 473.0 454.9 548.2 570.0
Apr 1961 503.6 463.0 442.9 547.7 572.6
May 1961 505.0 460.1 437.9 554.3 582.3
```

9.6. Модели ARIMA в среде R

| Lag | 1869 | 1870 | 1871 | 1872 | 1873 | 1874 | 1875 | ... |
|-----|------|------|------|------|------|------|------|-----|
| 0 | | | 1120 | 1160 | 963 | 1210 | 1160 | ... |
| 1 | | 1120 | 1160 | 963 | 1210 | 1160 | 1160 | ... |
| 2 | 1120 | 1160 | 963 | 1210 | 1160 | 1160 | 813 | ... |

Лаг – сдвиг влево временного ряда на заданное число наблюдений ($\text{lag}(ts, k)$)

Автокорреляция – оценивает силу связи, которой связаны уровни ряда с некоторым лагом.

График автокорреляционной функции $\text{Acf}(ts)$

Частная автокорреляция

Стационарность, разность

Дополненная процедура Дикки-Фуллера - `adf.test()` из пакета `tseries`

9.6. Модели ARIMA в среде R

Авторегрессионная модель порядка p

$$AR(p): Y_t = \mu + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \dots + \beta_p Y_{t-p} + \varepsilon_t$$

Модель скользящего среднего порядка q

$$MA(q): Y_t = \mu - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} \dots - \theta_q \varepsilon_{t-q} + \varepsilon_t$$

ARMA(p, q)

$$Y_t = \mu + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \dots + \beta_p Y_{t-p} - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} \dots - \theta_q \varepsilon_{t-q} + \varepsilon_t$$

ARIMA(p, d, q) Находятся разности d раз. Прогнозные значения получены на основании p текущих значений и q предыдущих ошибок. Прогнозные значения «интегрированы».

Применение модели ARIMA

1. Убедиться, что временной ряд стационарен.
2. Идентифицировать модель (выбрать p и q).
3. Подогнать модель.
4. Оценить модель.
5. Сделать прогноз.

9.6. Модели ARIMA в среде R

ПРОВЕРКА СТАЦИОНАРНОСТИ РЯДА


```
> library(forecast)
> library(tseries)
> plot(Nile)
> ndiffs(Nile)
```

```
[1] 1
```

```
> dNile <- diff(Nile)
> plot(dNile)
> adf.test(dNile)
```

Augmented Dickey-Fuller Test

```
data: dNile
Dickey-Fuller = -6.5924, Lag order = 4, p-value = 0.01
alternative hypothesis: stationary
```





9.6. Модели ARIMA в среде R

ИДЕНТИФИКАЦИЯ МОДЕЛИ

| Model | ACF | PACF |
|----------------|--------------------|--------------------|
| ARIMA(p, d, 0) | Trails off to zero | Zero after lag p |
| ARIMA(0, d, q) | Zero after lag q | Trails off to zero |
| ARIMA(p, d, q) | Trails off to zero | Trails off to zero |

`Acf(dNile)`

`Pacf(dNile)`



9.6. Модели ARIMA в среде R

ПОДГОНКА МОДЕЛИ

```
> library(forecast)
> fit <- arima(Nile, order=c(0,1,1))
> fit

Series: Nile
ARIMA(0,1,1)

Coefficients:
          ma1
        -0.7329
s.e.      0.1143

sigma^2 estimated as 20600:  log likelihood=-632.55
AIC=1269.09   AICc=1269.22   BIC=1274.28

> accuracy(fit)

              ME  RMSE  MAE   MPE  MAPE  MASE
Training set -11.94 142.8 112.2 -3.575 12.94 0.8089
```


9.6. Модели ARIMA в среде R

ОЦЕНКА МОДЕЛИ

```
> qqnorm(fit$residuals)
> qqline(fit$residuals)
> Box.test(fit$residuals, type="Ljung-Box")
```

Box-Ljung test

```
data: fit$residuals
X-squared = 1.3711, df = 1, p-value = 0.2416
```




9.6. Модели ARIMA в среде R

ПРОГНОЗИРОВАНИЕ

```
> forecast(fit, 3)
```

| | Point Forecast | Lo 80 | Hi 80 | Lo 95 | Hi 95 |
|------|----------------|----------|----------|----------|----------|
| 1971 | 798.3673 | 614.4307 | 982.3040 | 517.0605 | 1079.674 |
| 1972 | 798.3673 | 607.9845 | 988.7502 | 507.2019 | 1089.533 |
| 1973 | 798.3673 | 601.7495 | 994.9851 | 497.6663 | 1099.068 |

```
> plot(forecast(fit, 3), xlab="Year", ylab="Annual Flow")
```



9.6. Модели ARIMA в среде R

Автоматическое прогнозирование модели ARIMA

```
> library(forecast)
> fit <- auto.arima(sunspots)
> fit
Series: sunspots
ARIMA(2,1,2)

Coefficients:
      ar1      ar2      ma1      ma2
      1.35  -0.396  -1.77   0.810
s.e.   0.03   0.029   0.02   0.019

sigma^2 estimated as 243:  log likelihood=-11746
AIC=23501  AICc=23501  BIC=23531

> forecast(fit, 3)

      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
Jan 1984      40.437722  20.4412613  60.43418   9.855774  71.01967
Feb 1984      41.352897  18.2795867  64.42621   6.065314  76.64048
Mar 1984      39.796425  15.2537785  64.33907   2.261686  77.33116

> accuracy(fit)
      ME RMSE      MAE MPE MAPE MASE
Training set -0.02673 15.6 11.03 NaN  Inf  0.32
```

Литература

Robert I. Kabacoff R in Action, Second Edition. Data analysis and graphics with R