Липецкий государственный технический университет

Кафедра прикладной математики

КОМПЬЮТЕРНЫЕ ТЕХНОЛОГИИ МАТЕМАТИЧЕСКИХ ИССЛЕДОВАНИЙ

Лекция 13

Deep Learning в R

Составитель - Сысоев А.С., к.т.н., доцент

Липецк - 2022

Outline

15.1. Сверточные нейронные сети

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

15.3. Использование предварительно обученной сверточной нейронной сети

ОПЕРАЦИЯ СВЕРТЫВАНИЯ

Основное отличие полносвязного слоя от сверточного заключается в следующем: полносвязные (dense) слои изучают глобальные шаблоны в пространстве входных признаков (в случае с цифрами – это шаблоны, вовлекающие все пикселы), тогда как сверточные слои изучают локальные шаблоны (в случае с изображениями — шаблоны в небольших двумерных окнах во входных данных).

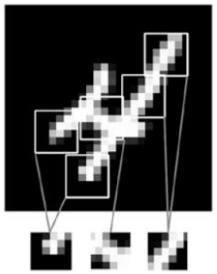

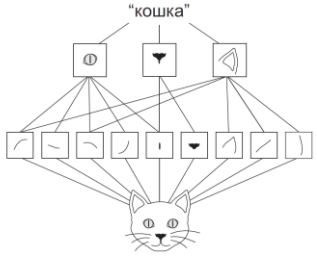

- Шаблоны, которые они изучают, являются инвариантными в отношении переноса. После изучения определенного шаблона в правом нижнем углу картинки сверточная нейронная сеть сможет распознавать его повсюду: например, в левом верхнем углу. Полносвязной сети пришлось бы изучить шаблон заново, если он появляется в другом месте. *Видимый мир по своей сути является инвариантным в отношении переноса*.
- Они могут изучать пространственные иерархии шаблонов. Первый сверточный слой будет изучать небольшие локальные шаблоны, такие как края, второй — более крупные шаблоны, состоящие из признаков, возвращаемых первым слоем, и т.д. Видимый мир формируется пространственными иерархиями видимых модулей: гиперлокальные края объединяются в локальные объекты, такие как глаза или уши, которые, в свою очередь, объединяются в понятия еще более высокого уровня, такие как «кошка».

15.1. Сверточные нейронные сети

ОПЕРАЦИЯ СВЕРТЫВАНИЯ

- Свертка применяется к трехмерным тензорам, называемым *картами признаков*, с двумя *пространственными осями* (высота и ширина), а также *с осью глубины* (или *осью каналов*).
- Операция свертывания извлекает шаблоны из своей входной карты признаков и применяет одинаковые преобразования ко всем шаблонам, производя *выходную карту признаков*.
- Глубина карты может иметь любую размерность, потому что выходная глубина является параметром слоя, и разные каналы на этой оси глубины больше не соответствуют конкретным цветам, как во входных данных в формате RGB; они соответствуют *фильтрам*. Фильтры представляют конкретные аспекты входных данных: на верхнем уровне, например, фильтр может соответствовать понятию «присутствие лица на входе».
- Свертки определяются двумя ключевыми параметрами:
  - размером шаблонов, извлекаемых из входных данных — обычно 3 x 3 или 5 x 5;
  - глубиной выходной карты признаков — количеством фильтров, вычисляемых сверткой.
- В Keras эти параметры передаются в слой в первых аргументах:

```
layer_conv_2d (выходная_глубина, c (высота_окна, ширина_окна))
```

15.1. Сверточные нейронные сети

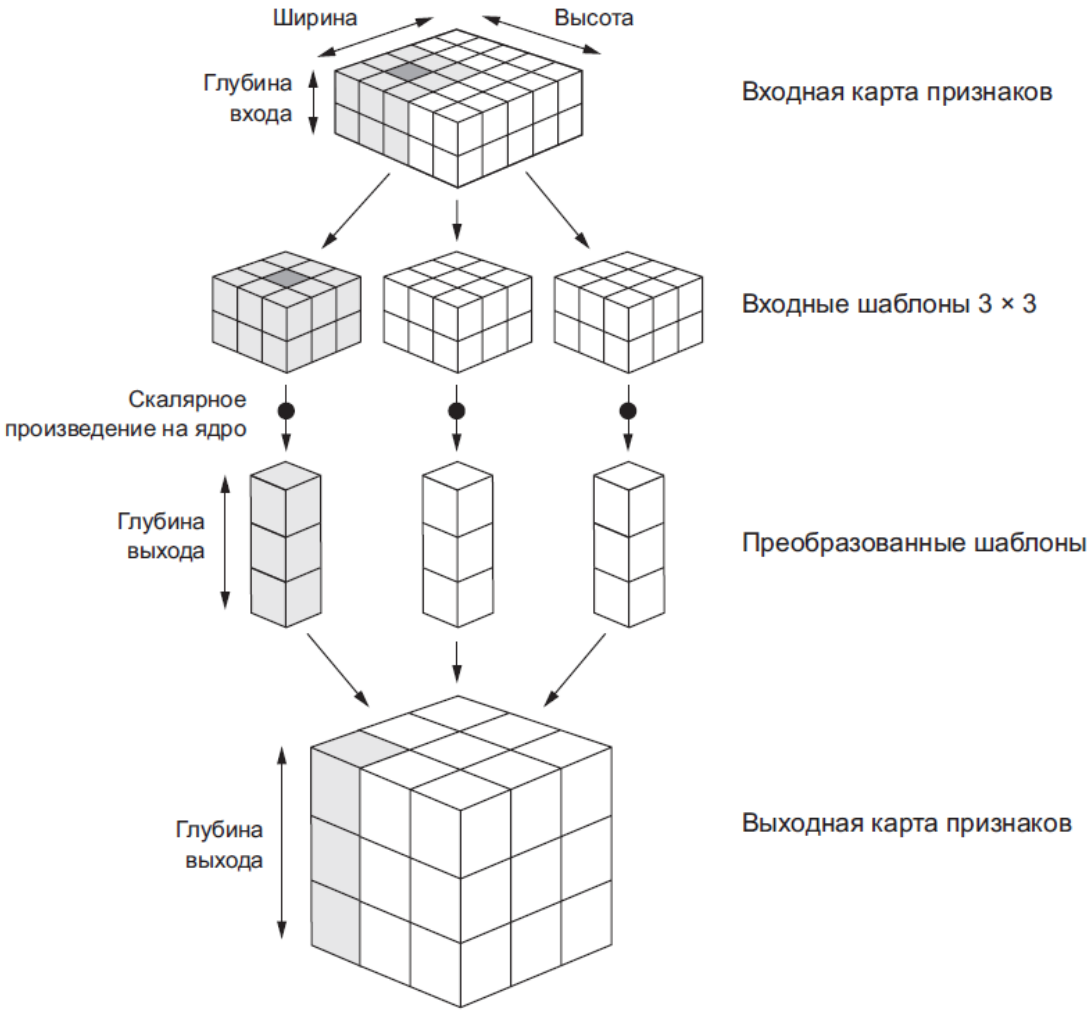

Выходные ширина и высота могут отличаться от входных.

На то есть две причины:

- эффекты границ, которые могут устраняться дополнением входной карты признаков;
- использование шага свертки

ЭФФЕКТЫ ГРАНИЦ И ДОПОЛНЕНИЕ

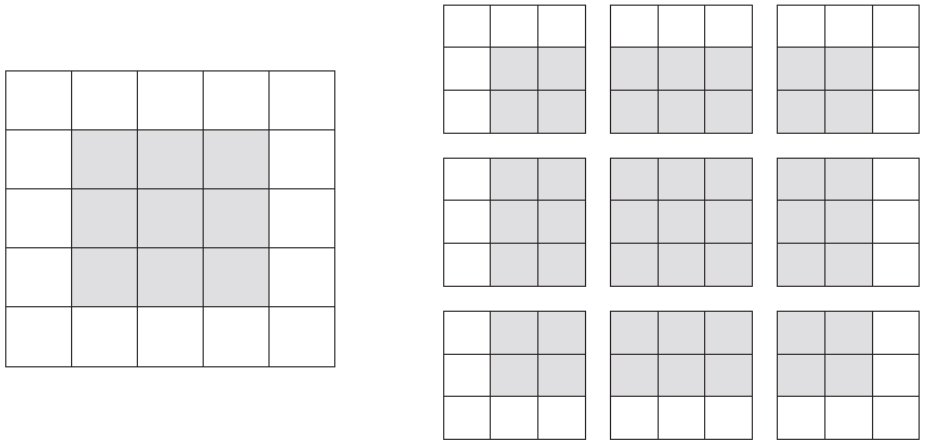

- Карта признаков 5 × 5 (всего 25 клеток).
- Существует всего 9 клеток, в которых может находиться центр окна 3 × 3, образующих сетку 3 × 3. Следовательно, карта выходных признаков будет иметь размер 3 × 3.
- Она сжатая — ровно на две клетки вдоль каждого измерения.

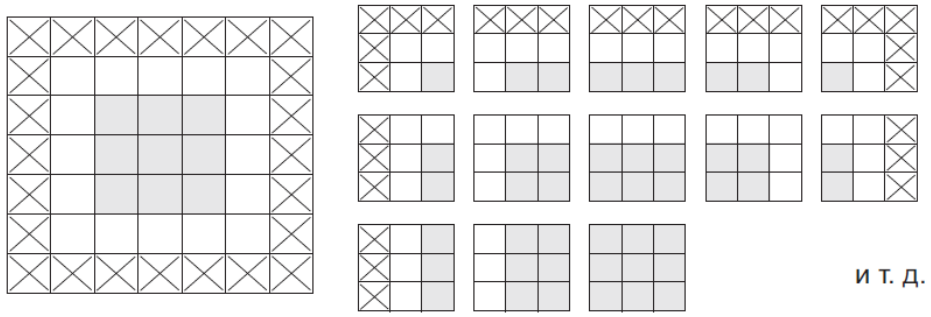

- Дополнение заключается в добавлении соответствующего количества строк и столбцов с каждой стороны входной карты признаков, чтобы можно было поместить центр окна свертки в каждую входную клетку.

При использовании слоев `layer_conv_2d` дополнение настраивается с помощью аргумента `padding`, который принимает два значения: `valid` (будут использоваться только допустимые местоположения окна), и `same` (дополнить так, чтобы выходная карта признаков имела ту же ширину и высоту, что и входная).

15.1. Сверточные нейронные сети

ШАГ СВЕРТКИ

В общем случае расстояние между двумя соседними окнами является настраиваемым параметром, который называется шагом свертки и по умолчанию равен 1.

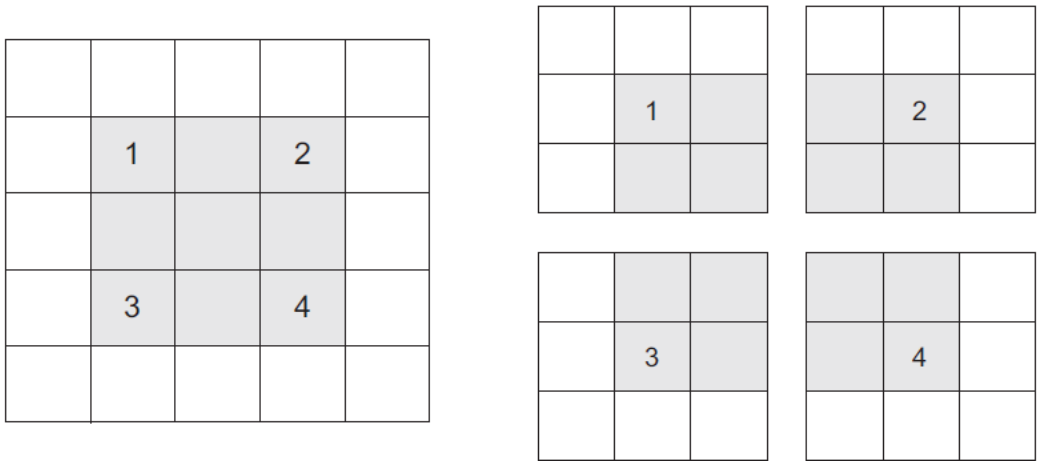

- Использование шага 2 означает уменьшение ширины и высоты карты признаков за счет уменьшения разрешения в 2 раза (в дополнение к любым изменениям, вызванным эффектами границ).
- Для уменьшения разрешения карты признаков вместо шага часто используется операция выбора максимального значения из соседних (max-pooling).

Из входной карты признаков извлекается окно и из него выбирается максимальное значение для каждого канала. Концептуально это напоминает свертку, но вместо преобразования локальных шаблонов с обучением на линейных преобразованиях (ядро свертки) они преобразуются с использованием жестко заданной тензорной операции выбора максимального значения. Главное отличие от свертки состоит в том, что выбор максимального значения из соседних обычно производится с окном 2 × 2 и шагом 2, чтобы уменьшить разрешение карты признаков в 2 раза.

```
model_no_max_pool <- keras_model_sequential() %>%
  layer_conv_2d(filters = 32, kernel_size = c(3, 3), activation = "relu",
                input_shape = c(28, 28, 1)) %>%
  layer_conv_2d(filters = 64, kernel_size = c(3, 3), activation = "relu") %>%
  layer_conv_2d(filters = 64, kernel_size = c(3, 3), activation = "relu")
```

Сводная информация о модели:

```
> model_no_max_pool

Layer (type)                 Output Shape              Param #
================================================================
conv2d_4 (Conv2D)            (None, 26, 26, 32)        320
________________________________________________________________
conv2d_5 (Conv2D)            (None, 24, 24, 64)        18496
________________________________________________________________
conv2d_6 (Conv2D)            (None, 22, 22, 64)        36928
================================================================
Total params: 55,744
Trainable params: 55,744
Non-trainable params: 0
```

Уменьшение разрешения используется для уменьшения количества коэффициентов в карте признаков для обработки, а также внедрения иерархий пространственных фильтров путем создания последовательных уровней свертки для просмотра все более крупных окон (с точки зрения долей исходных данных, которые они охватывают).

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

Классификация изображений собак и кошек из набора данных, содержащего 4000 изображений (2000 кошек, 2000 собак). Мы будем использовать 2000 изображений для обучения, 1000 для проверки и 1000 для контроля.

```
original_dataset_dir <- "~/Downloads/kaggle_original_data"

base_dir <- "~/Downloads/cats_and_dogs_small"
dir.create(base_dir)

train_dir <- file.path(base_dir, "train")
dir.create(train_dir)
```

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

Сверточная нейронная сеть будет организована как стек чередующихся уровней `layer_conv_2d` (с функцией активации `relu`) и `layer_max_pooling_2d`. Сеть будет иметь на одну пару уровней `layer_conv_2d + layer_max_pooling_2d` больше. Это увеличит ее емкость и обеспечит дополнительное снижение размеров карт признаков, чтобы они не оказались слишком большими, когда достигнут уровня `layer_flatten`.

```
library(keras)

model <- keras_model_sequential() %>%
  layer_conv_2d(filters = 32, kernel_size = c(3, 3), activation = "relu",
                input_shape = c(150, 150, 3)) %>%
  layer_max_pooling_2d(pool_size = c(2, 2)) %>%
  layer_conv_2d(filters = 64, kernel_size = c(3, 3),
                activation = "relu") %>%
  layer_max_pooling_2d(pool_size = c(2, 2)) %>%
  layer_conv_2d(filters = 128, kernel_size = c(3, 3),
                activation = "relu") %>%
  layer_max_pooling_2d(pool_size = c(2, 2)) %>%
  layer_conv_2d(filters = 128, kernel_size = c(3, 3),
                activation = "relu") %>%
  layer_max_pooling_2d(pool_size = c(2, 2)) %>%
  layer_flatten() %>%
  layer_dense(units = 512, activation = "relu") %>%
  layer_dense(units = 1, activation = "sigmoid")
```

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

```
> summary(model)

Layer (type)                 Output Shape              Param #
=================================================================
conv2d_1 (Conv2D)            (None, 148, 148, 32)      896
_________________________________________________________________
maxpooling2d_1 (MaxPooling2D)(None, 74, 74, 32)        0
_________________________________________________________________
conv2d_2 (Conv2D)            (None, 72, 72, 64)        18496
_________________________________________________________________
maxpooling2d_2 (MaxPooling2D)(None, 36, 36, 64)        0
_________________________________________________________________
conv2d_3 (Conv2D)            (None, 34, 34, 128)       73856
_________________________________________________________________
maxpooling2d_3 (MaxPooling2D)(None, 17, 17, 128)       0
_________________________________________________________________
conv2d_4 (Conv2D)            (None, 15, 15, 128)       147584
_________________________________________________________________
maxpooling2d_4 (MaxPooling2D)(None, 7, 7, 128)         0
_________________________________________________________________
flatten_1 (Flatten)          (None, 6272)              0
_________________________________________________________________
dense_1 (Dense)              (None, 512)               3211776
_________________________________________________________________
dense_2 (Dense)              (None, 1)                 513
=================================================================

Total params: 3,453,121
Trainable params: 3,453,121
Non-trainable params: 0
```

```
model %>% compile(
  loss = "binary_crossentropy",
  optimizer = optimizer_rmsprop(lr = 1e-4),
  metrics = c("acc")
)
```

ПРЕДВАРИТЕЛЬНАЯ ОБРАБОТКА ДАННЫХ

В настоящее время данные хранятся в виде файлов JPEG, поэтому их нужно подготовить для передачи в сеть, выполнив следующие шаги:

1. Прочитать файлы с изображениями.

2. Декодировать содержимое из формата JPEG в таблицы пикселов RGB.

3. Преобразовать их в тензоры с вещественными числами.

4. Масштабировать значения пикселов из диапазона [0, 255] в диапазон [0, 1] (как вы уже знаете, нейронным сетям предпочтительнее передавать небольшие значения).

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

```
train_datagen <- image_data_generator(rescale = 1/255)
validation_datagen <- image_data_generator(rescale = 1/255)

train_generator <- flow_images_from_directory(
  train_dir,
  train_datagen,
  target_size = c(150, 150),

  batch_size = 20,
  class_mode = «binary»
)

validation_generator <- flow_images_from_directory(
  validation_dir,
  validation_datagen,
  target_size = c(150, 150),
  batch_size = 20,
  class_mode = «binary»
)
```

Масштабировать значения с коэффициентом 1/255

Целевой каталог

Генератор данных обучения

Привести все изображения к размеру 150 × 150

Так как используется функция потерь binary_crossentropy, метки должны быть бинарными

```
> batch <- generator_next(train_generator)
> str(batch)
List of 2
  $ : num [1:20, 1:150, 1:150, 1:3] 37 48 153 53 114 194 158 141 255 167 ...
  $ : num [1:20(1d)] 1 1 1 1 0 1 1 0 1 1 ...
```

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

Обучение модели с использованием генератора пакетов

```
history <- model %>% fit_generator(
  train_generator,
  steps_per_epoch = 100,
  epochs = 30,
  validation_data = validation_generator,
  validation_steps = 50
)
```

Сохранение модели

```
model %>% save_model_hdf5("cats_and_dogs_small_1.h5")
```

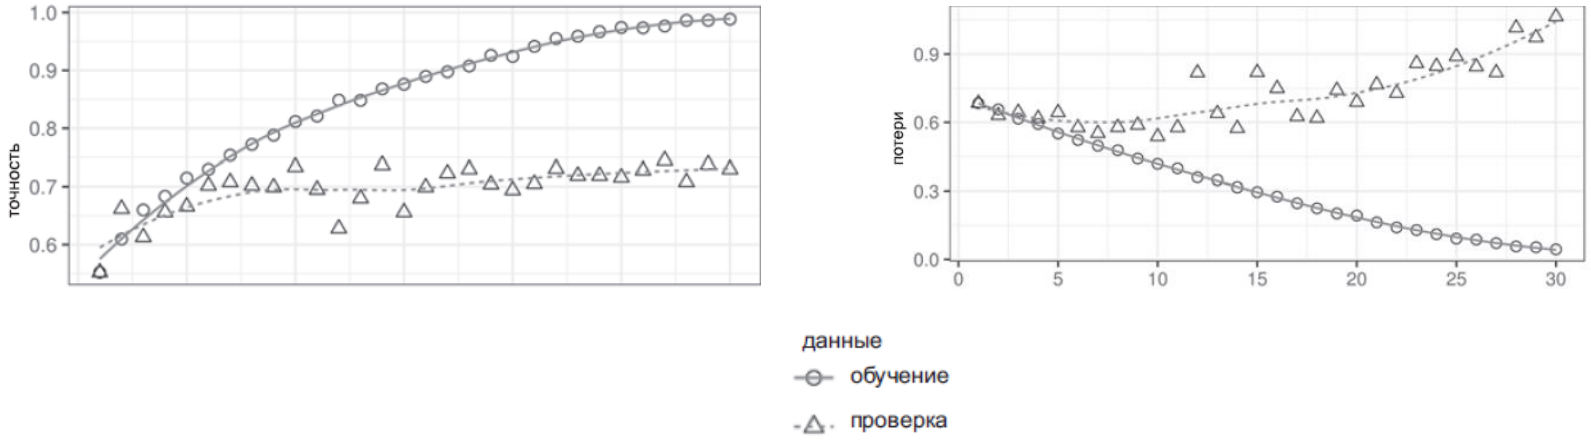

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

РАСШИРЕНИЕ ДАННЫХ

Цель состоит в том, чтобы на этапе обучения модель никогда не увидела одно и то же изображение дважды. Это поможет модели выявить больше особенностей данных и достичь лучшей степени обобщения.

```
datagen <- image_data_generator(
  rescale = 1/255,
  rotation_range = 40,
  width_shift_range = 0.2,
  height_shift_range = 0.2,
  shear_range = 0.2,
  zoom_range = 0.2,
  horizontal_flip = TRUE,
  fill_mode = "nearest"
)
```

`rotation_range` — величина в градусах (0–180), диапазон, в котором будет осуществляться случайный поворот изображения;
`width_shift` и `height_shift` — диапазоны (в долях ширины и высоты), в пределах которых изображения смещаются по горизонтали и по вертикали соответственно;
`shear_range` — для случайного применения сдвигового (shearing) преобразования;
`zoom_range` — для случайного изменения масштаба внутри изображений;
`horizontal_flip` — для случайного переворачивания половины изображения по горизонтали — подходит в случаях отсутствия предположений о горизонтальной асимметрии (например, в изображениях реального мира);
`fill_mode` — стратегия заполнения вновь созданных пикселов, появляющихся после поворота или смещения по горизонтали/вертикали.

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

Отображение некоторых обучающих изображений, подвергшихся случайным преобразованиям

```
fnames <- list.files(train_cats_dir, full.names = TRUE)
img_path <- fnames[[3]]

img <- image_load(img_path, target_size = c(150, 150))
img_array <- image_to_array(img)
img_array <- array_reshape(img_array, c(1, 150, 150, 3))

augmentation_generator <- flow_images_from_data(
  img_array,
  generator = datagen,
  batch_size = 1
)

op <- par(mfrow = c(2, 2), pty = «s», mar = c(1, 0, 1, 0))
for (i in 1:4) {
  batch <- generator_next(augmentation_generator)
  plot(as.raster(batch[1,,,]))
}

par(op)
```

Выбор одного изображения для расширения

Прочитать изображение и изменить его размеры

Преобразовать в массив с формой (150, 150, 3)

Изменить форму на (1, 150, 150, 3)

Сгенерировать пакеты случайно преобразованных изображений. Цикл выполняется бесконечно, поэтому его нужно принудительно прервать в некоторый момент!

Вывод изображений

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

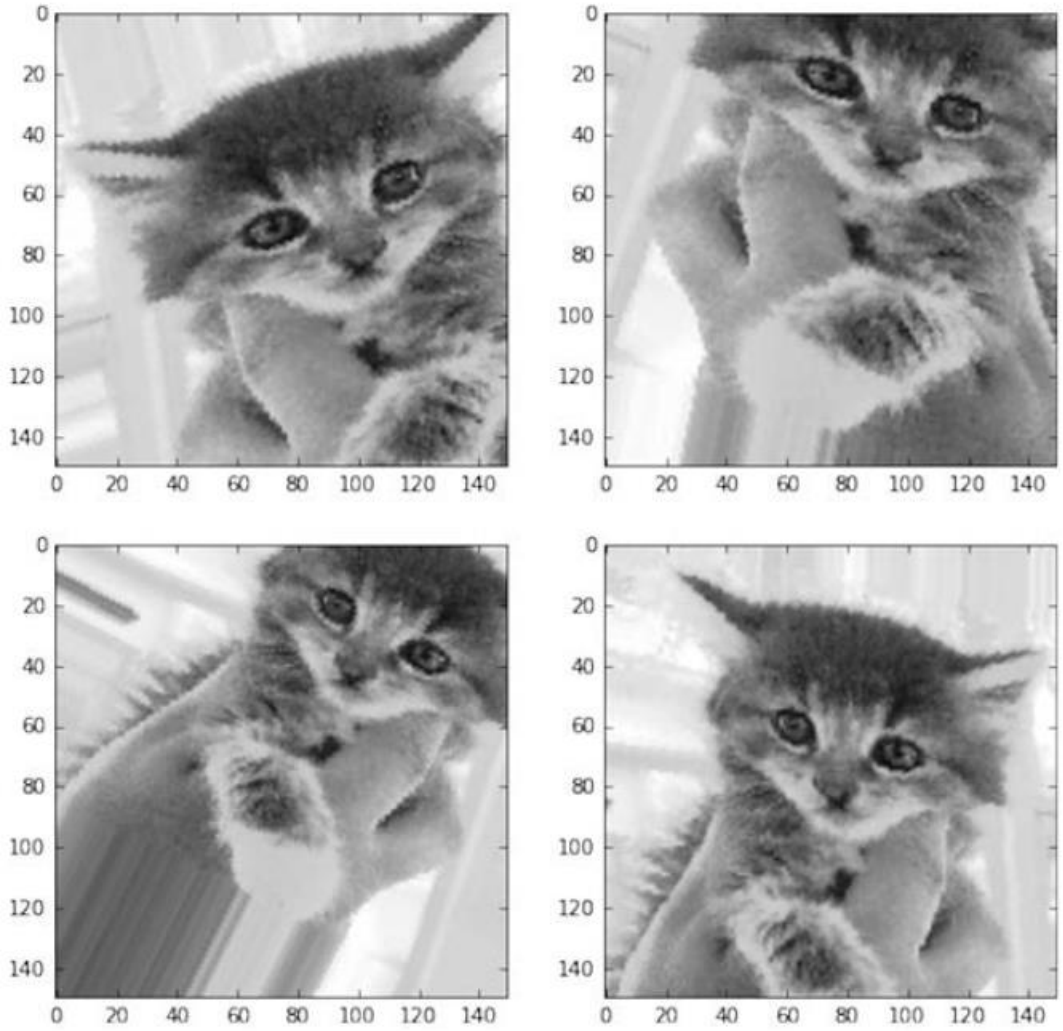

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

Обучение сверточной нейронной сети с использованием генераторов расширения данных

```
datagen <- image_data_generator(
  rescale = 1/255,
  rotation_range = 40,
  width_shift_range = 0.2,
  height_shift_range = 0.2,
  shear_range = 0.2,
  zoom_range = 0.2,
  horizontal_flip = TRUE
)

test_datagen <-
      image_data_generator(rescale = 1/255)

train_generator <- flow_images_from_directory(
  train_dir,
  datagen,
  target_size = c(150, 150),
  batch_size = 32,
  class_mode = "binary"
)
```

Обратите внимание, что проверочные данные не требуется расширять!

Целевой каталог

Генератор данных

Привести все изображения к размеру 150 × 150

Так как используется функция потерь binary_crossentropy, метки должны быть бинарными

15.2. Обучение сверточной нейронной сети с нуля на небольшом наборе данных

```
validation_generator <- flow_images_from_directory(
  validation_dir,
  test_datagen,
  target_size = c(150, 150),
  batch_size = 32,
  class_mode = «binary»
)

history <- model %>% fit_generator(
  train_generator,
  steps_per_epoch = 100,
  epochs = 100,
  validation_data = validation_generator,
  validation_steps = 50
)
```

Сохранение модели

```
model %>% save_model_hdf5("cats_and_dogs_small_2.h5")
```

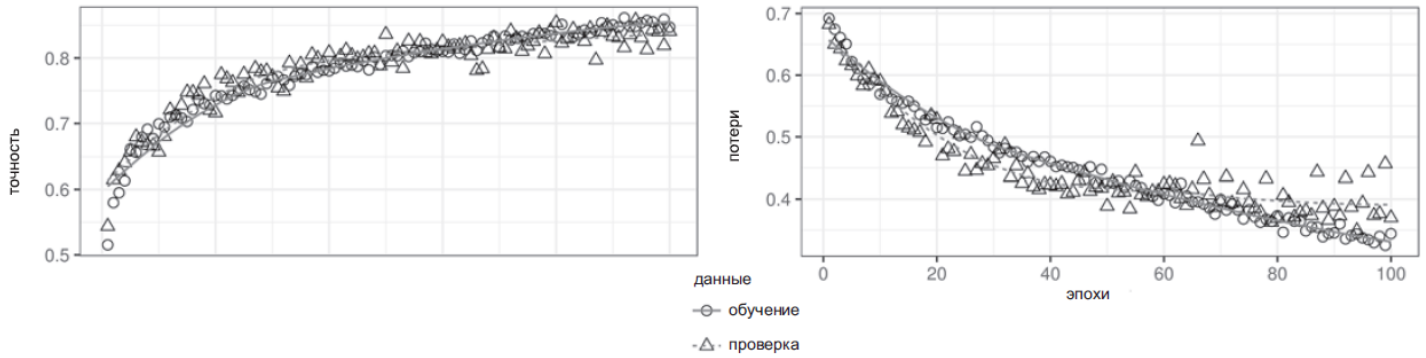

15.3. Использование предварительно обученной сверточной нейронной сети

Есть два приема использования предварительно обученных сетей: выделение признаков (feature extraction) и дообучение (fine-tuning).

ВЫДЕЛЕНИЕ ПРИЗНАКОВ

Выделение признаков заключается в использовании представлений, изученных предыдущей сетью, для выделения признаков из новых образцов, которые затем пропускаются через новый классификатор, обучаемый с нуля.

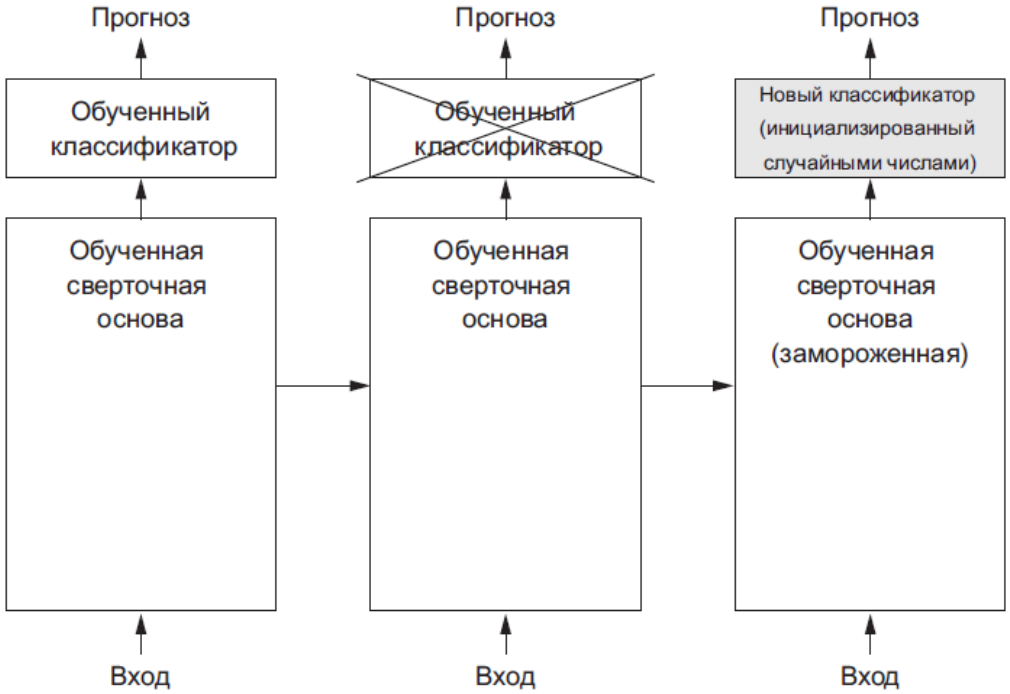

15.3. Использование предварительно обученной сверточной нейронной сети

Сверточная основа сети VGG16, обученной на данных ImageNet, для выделения полезных признаков из изображений кошек и собак.

```
library(keras)

conv_base <- application_vgg16(
  weights = "imagenet",
  include_top = FALSE,
  input_shape = c(150, 150, 3)
)
```

- `weights` определяет источник весов для инициализации модели.
- `include_top` определяет необходимость подключения к сети полносвязного классификатора.
- `input_shape` определяет форму тензоров с изображениями, которые будут подаваться на вход сети.

Далее можно пойти двумя путями:

- Пропустить набор данных через сверточную основу, записать получившийся массив на диск и затем использовать его как входные данные для отдельного полносвязного классификатора. Это быстрое и недорогое решение, потому что требует запускать сверточную основу только один раз для каждого входного изображения, а сверточная основа — самая дорогостоящая часть конвейера.
- Дополнить имеющуюся модель (conv_base) полносвязными слоями и пропустить все входные данные. Этот путь позволяет использовать расширение данных, потому что каждое изображение проходит через сверточную основу каждый раз, когда попадает в модель. Но по той же причине этот путь намного дороже первого.

15.3. Использование предварительно обученной сверточной нейронной сети

БЫСТРОЕ ВЫДЕЛЕНИЕ ПРИЗНАКОВ БЕЗ РАСШИРЕНИЯ ДАННЫХ

```
base_dir <- "~/Downloads/cats_and_dogs_small"
train_dir <- file.path(base_dir, "train")
validation_dir <- file.path(base_dir, "validation")
test_dir <- file.path(base_dir, "test")

datagen <- image_data_generator(rescale = 1/255)
batch_size <- 20

extract_features <- function(directory, sample_count) {

features <- array(0, dim = c(sample_count, 4, 4, 512))
labels <- array(0, dim = c(sample_count))

generator <- flow_images_from_directory(
  directory = directory,
  generator = datagen,
  target_size = c(150, 150),
  batch_size = batch_size,
  class_mode = "binary"
)
```

15.3. Использование предварительно обученной сверточной нейронной сети

БЫСТРОЕ ВЫДЕЛЕНИЕ ПРИЗНАКОВ БЕЗ РАСШИРЕНИЯ ДАННЫХ

```
  i <- 0
  while(TRUE) {
    batch <- generator_next(generator)
    inputs_batch <- batch[[1]]
    labels_batch <- batch[[2]]
    features_batch <- conv_base %>% predict(inputs_batch)

    index_range <- ((i * batch_size)+1):((i + 1) * batch_size)
    features[index_range,,,] <- features_batch
    labels[index_range] <- labels_batch
    i <- i + 1
    if (i * batch_size >= sample_count)
      break
  }

  list(
    features = features,
    labels = labels
  )
}

train <- extract_features(train_dir, 2000)
validation <- extract_features(validation_dir, 1000)
test <- extract_features(test_dir, 1000)
```

Обратите внимание: поскольку генераторы возвращают данные в цикле до бесконечности, мы должны прервать цикл после передачи всех изображений

15.3. Использование предварительно обученной сверточной нейронной сети

БЫСТРОЕ ВЫДЕЛЕНИЕ ПРИЗНАКОВ БЕЗ РАСШИРЕНИЯ ДАННЫХ

```
reshape_features <- function(features) {
  array_reshape(features, dim = c(nrow(features), 4 * 4 * 512))
}
train$features <- reshape_features(train$features)
validation$features <- reshape_features(validation$features)
test$features <- reshape_features(test$features)

model <- keras_model_sequential() %>%
  layer_dense(units = 256, activation = "relu",
              input_shape = 4 * 4 * 512) %>%
  layer_dropout(rate = 0.5) %>%
  layer_dense(units = 1, activation = "sigmoid")

model %>% compile(
  optimizer = optimizer_rmsprop(lr = 2e-5),
  loss = "binary_crossentropy",
  metrics = c("accuracy")
)

history <- model %>% fit(
  train$features, train$labels,
  epochs = 30,
  batch_size = 20,
  validation_data = list(validation$features, validation$labels)
)
```

15.3. Использование предварительно обученной сверточной нейронной сети

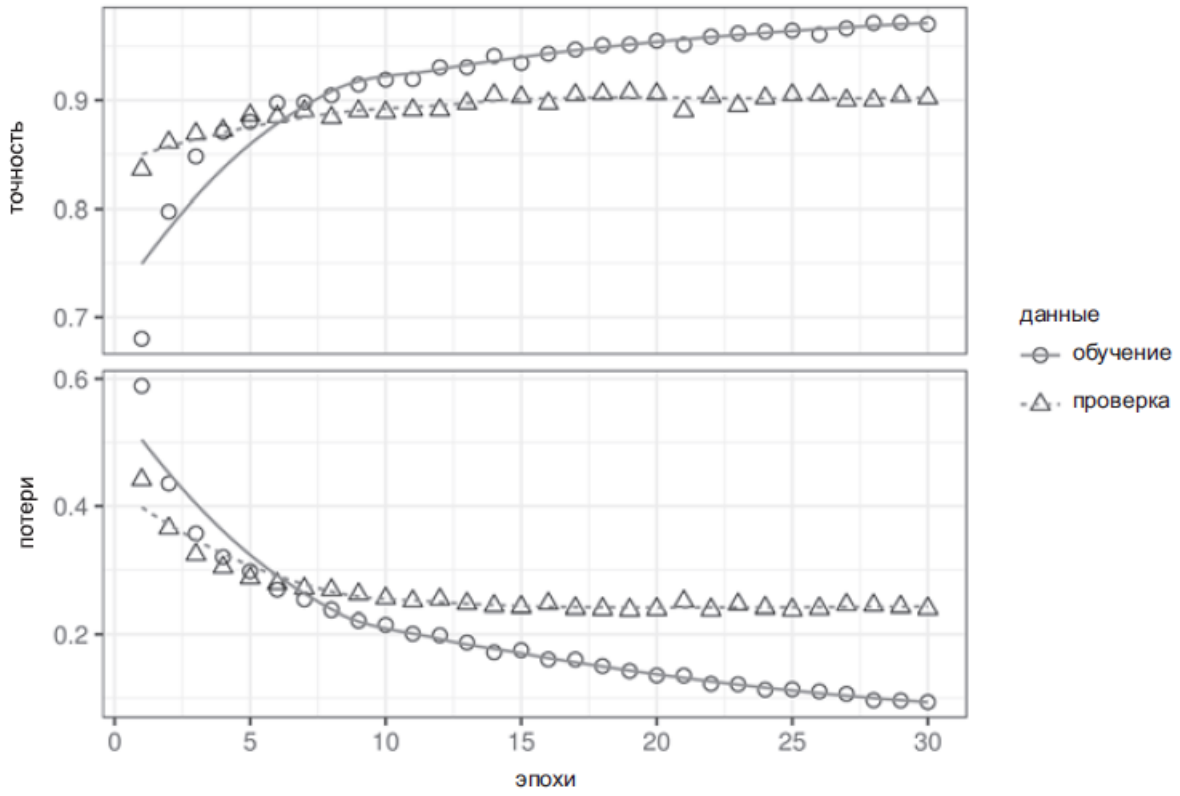

15.3. Использование предварительно обученной сверточной нейронной сети

ВЫДЕЛЕНИЕ ПРИЗНАКОВ С РАСШИРЕНИЕМ ДАННЫХ

Добавление полносвязного классификатора
поверх сверточной основы

```
model <- keras_model_sequential() %>%
  conv_base %>%
  layer_flatten() %>%
  layer_dense(units = 256, activation = "relu") %>%
  layer_dense(units = 1, activation = "sigmoid")
```

```
> model
```

```
Layer (type)                 Output Shape              Param #
=================================================================
vgg16 (Model)                (None, 4, 4, 512)         14714688
_________________________________________________________________
flatten_1 (Flatten)          (None, 8192)              0
_________________________________________________________________
dense_1 (Dense)              (None, 256)               2097408
_________________________________________________________________
dense_2 (Dense)              (None, 1)                 257
=================================================================
Total params: 16,812,353
Trainable params: 16,812,353
Non-trainable params: 0
```

Перед компиляцией и обучением модели очень важно заморозить сверточную основу. Замораживание одного или нескольких слоев предотвращает изменение весовых коэффициентов в них в процессе обучения. Если этого не сделать, тогда представления, прежде изученные сверточной основой, изменятся в процессе обучения на новых данных.

15.3. Использование предварительно обученной сверточной нейронной сети

ВЫДЕЛЕНИЕ ПРИЗНАКОВ С РАСШИРЕНИЕМ ДАННЫХ

```
train_datagen = image_data_generator(
  rescale = 1/255,
  rotation_range = 40,
  width_shift_range = 0.2,
  height_shift_range = 0.2,
  shear_range = 0.2,
  zoom_range = 0.2,
  horizontal_flip = TRUE,
  fill_mode = "nearest"
)

test_datagen <-
      image_data_generator(rescale = 1/255)

train_generator <- flow_images_from_directory(
  train_dir,
  train_datagen,
  target_size = c(150, 150),
  batch_size = 20,
  class_mode = «binary»
)
```

Обратите внимание, что проверочные данные не требуется расширять!

Целевой каталог

Генератор данных

Привести все изображения к размеру 150 × 150

15.3. Использование предварительно обученной сверточной нейронной сети

ВЫДЕЛЕНИЕ ПРИЗНАКОВ С РАСШИРЕНИЕМ ДАННЫХ

```
validation_generator <- flow_images_from_directory(
  validation_dir,
  test_datagen,
  target_size = c(150, 150),
  batch_size = 20,
  class_mode = "binary"
)

model %>% compile(
  loss = "binary_crossentropy"
  optimizer = optimizer_rmsprop(lr = 2e-5),
  metrics = c("accuracy")
)

history <- model %>% fit_generator(
  train_generator,
  steps_per_epoch = 100,
  epochs = 30,
  validation_data = validation_generator,
  validation_steps = 50
)
```

15.3. Использование предварительно обученной сверточной нейронной сети

ВЫДЕЛЕНИЕ ПРИЗНАКОВ С РАСШИРЕНИЕМ ДАННЫХ

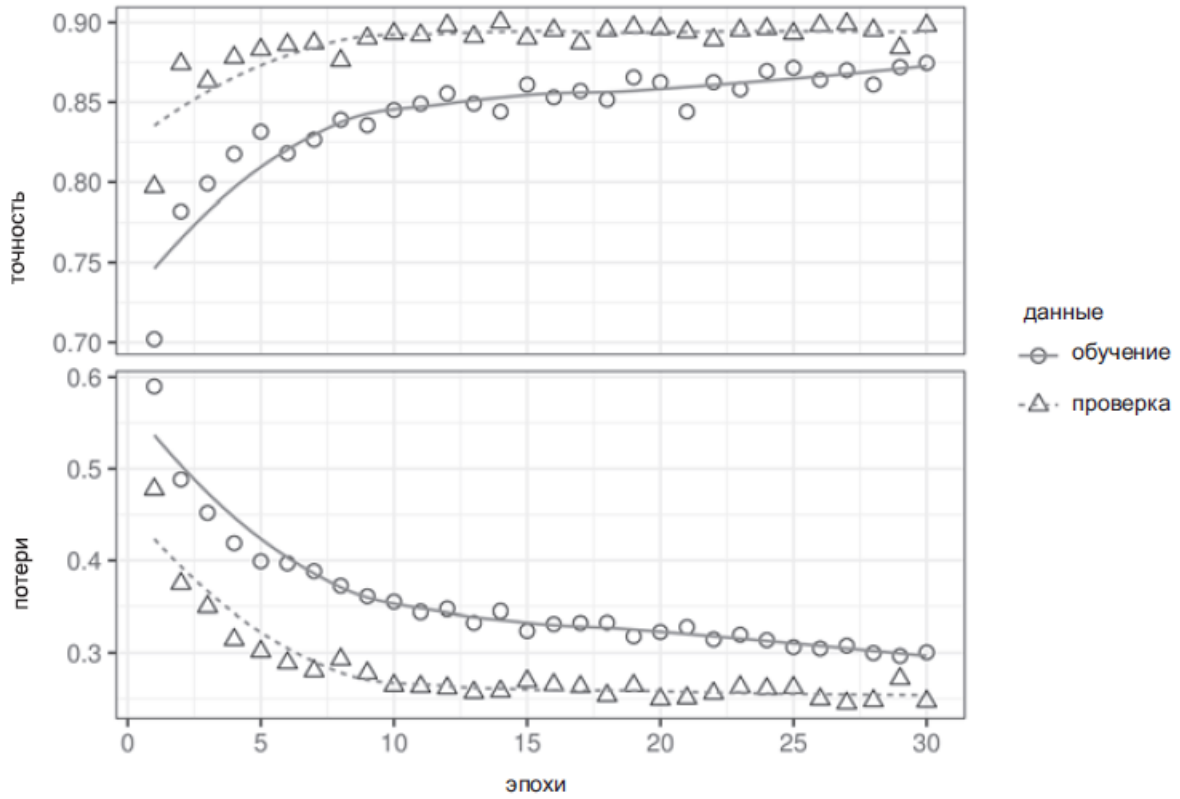

15.3. Использование предварительно обученной сверточной нейронной сети

ДООБУЧЕНИЕ

Дообучение заключается в размораживании нескольких верхних уровней замороженной модели, использовавшейся для выделения признаков, и совместное обучение вновь добавленной части модели (в данном случае полносвязного классификатора) и этих верхних уровней.

15.3. Использование предварительно обученной сверточной нейронной сети

ДООБУЧЕНИЕ

Для дообучения сети требуется выполнить следующие шаги:

1. Добавить свою сеть поверх обученной базовой сети.

2. Заморозить базовую сеть.

3. Обучить добавленную часть.

4. Разморозить несколько слоев в базовой сети.

15. Обучить эти слои и добавленную часть вместе.

```
model %>% compile(
  loss = "binary_crossentropy",
  optimizer = optimizer_rmsprop(lr = 1e-5),
  metrics = c("accuracy")
)

history <- model %>% fit_generator(
  train_generator,
  steps_per_epoch = 100,
  epochs = 100,
  validation_data = validation_generator,
  validation_steps = 50
)
```

15.3. Использование предварительно обученной сверточной нейронной сети

ДООБУЧЕНИЕ

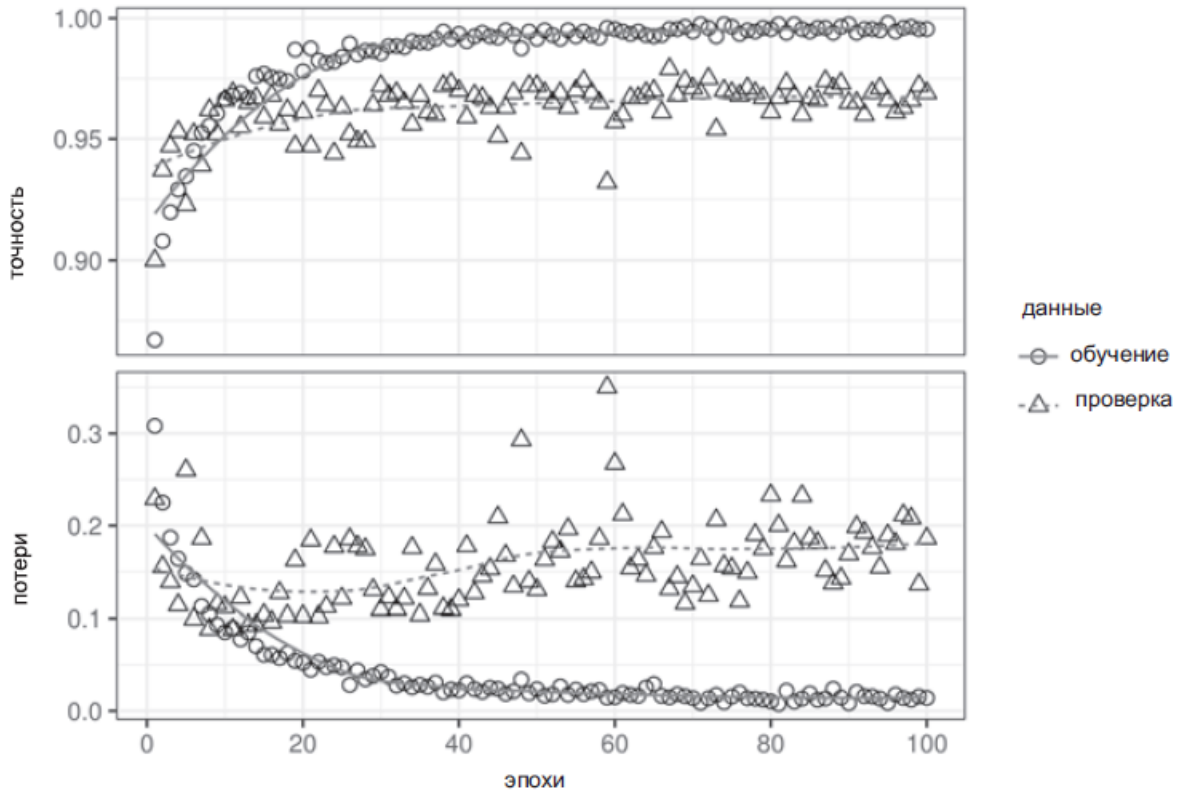

Итоги

- Сверточные нейронные сети — лучший тип моделей машинного обучения для задач распознавания образов. Вполне можно обучить такую сеть с нуля на очень небольшом наборе данных и получить приличный результат.
- Когда объем данных ограничен, главной проблемой становится переобучение. Расширение данных — мощное средство борьбы с переобучением при работе с изображениями.
- Существующую сверточную нейронную сеть с легкостью можно повторно использовать на новом наборе данных, применив прием выделения признаков. Этот прием особенно ценен при работе с небольшими наборами изображений.
- В дополнение к выделению признаков можно использовать прием дообучения, который адаптирует к новой задаче некоторые из представлений, ранее полученных существующей моделью. Он еще больше повышает качество модели.